



**YILDIZ TEKNİK ÜNİVERSİTESİ
KİMYA-METALÜRJİ FAKÜLTESİ
MATEMATİK MÜHENDİSLİĞİ BÖLÜMÜ**

BİTİRME ÇALIŞMASI

**BİNARY SINIFLANDIRMA PROBLEMLERİNDE
FARKLI MAKİNE ÖĞRENMESİ
ALGORİTMALARININ PERFORMANS ANALİZİ
VE KARŞILAŞTIRILMASI**

19052505- Tahire Gülnur TURANLI

Tez Danışmanı: Doç. Dr. Müslüm ÖZİŞİK

Haziran, İstanbul, 2026



**YILDIZ TEKNİK ÜNİVERSİTESİ
KİMYA-METALÜRJİ FAKÜLTESİ
MATEMATİK MÜHENDİSLİĞİ BÖLÜMÜ**

BİTİRME ÇALIŞMASI

**BİNARY SINIFLANDIRMA PROBLEMLERİNDE
FARKLI MAKİNE ÖĞRENMESİ
ALGORİTMALARININ PERFORMANS ANALİZİ
VE KARŞILAŞTIRILMASI**

19052505- Tahire Gülnur TURANLI

Tez Danışmanı: Doç. Dr. Müslüm ÖZİŞİK

Haziran, İstanbul, 2026

İÇİNDEKİLER

İçindekiler Tablosu

İÇİNDEKİLER	ii
SEMBOL LİSTESİ	iv
KISALTMA LİSTESİ	v
TABLO LİSTESİ	vii
ÖNSÖZ	viii
ÖZET	ix
ABSTRACT	x
1.GİRİŞ	1
2. LİTERATÜR TARAMASI	3
2.1. Sınıflandırma Algoritmalarının Tarihsel Gelişimi	3
2.2. İkili Sınıflandırmada Karşılaştırmalı Çalışmalar	4
3.TEORİK ALTYAPI VE ALGORİTMALAR	6
3.1. Logistik Regresyon	6
3.2. Destek Vektör Makinesi	7
3.3. Random Forest	8
3.4. XGBoost	8
4. METODOLOJİ VE UYGULAMA	10
4.1. Veri Setinin Tanıtılması	10
4.2. Veri Ön İşleme	10
4.3. Sınıf Dengesizliğinin Giderilmesi	11
4.4. Pipeline Mimarisi	11
4.5. Model Parametreleri	12
4.6. Değerlendirme Yöntemi	12
5. PERFORMANS METRİKLERİ	13
5.1. Karmaşıklık Matrisi	13
5.2. Doğruluk	13
5.3. Kesinlik	13
5.4. Duyarlılık	14
5.5. F1- Skoru	14
5.6. ROC Eğrisi ve AUC	14
5.7. Metriklerin Karşılaştırılması	15
6. BULGULAR VE KARŞILAŞTIRMALI ANALİZ	16

6.1. Genel Performans Karşılaştırması.....	16
6.2. Doğruluk ve F1-Skoru Analizi.....	16
6.3. Kesinlik-Duyarlılık Dengesi	16
6.4. ROC Eğrisi Analizi	17
6.5. XGBoost Karmaşıklık Matrisi Analizi.....	18
6.6 XGBoost Öznitelik Önemi Analizi	19
6.7. Sayısal Öznitelikler Arası Korelasyon Analizi	20
6.8. Algoritmaların Genel Değerlendirmesi.....	21
7. SONUÇ VE ÖNERİLER.....	22
7.1 Genel Sonuçlar	22
7.2 Çalışmanın Katkıları	23
7.3 Sınırlılıklar	23
7.4 Gelecek Çalışma Önerileri	23
KAYNAKÇA	24
ÖZGEÇMİŞ.....	25

SEMBOL LİSTESİ

b	Önyargı terimi
C	DVM yumuşak marjin düzenleme parametresi
$F(x)$	Model tahmin fonksiyonu
g	Kayıp fonksiyonun birinci türevi(gradyan)
$Gini$	Gini safsızlık indeksi
$H(x)$	Random Forest topluluk karar fonksiyonu
I	Gösterge fonksiyonu
K	Kernel fonksiyonu
L	Log-likelihood fonksiyonu
$\bar{m}$	Çapraz doğrulama ortalama metrik değeri
p	Sınıflara ait örnek oranı
P	Olasılık
PE	Random Forest genelleme hatası üst sınırı
r_{XY}	Pearson korelasyon katsayısı
s	Bireysel ağaçların gücü
w	Ağırlık vektörü
w^*	Optimal ağırlık değeri
x	Girdi öznitelik vektörü
y	Gerçek sınıf etiketi
z	Doğrusal kombinasyon değeri
β	Katsayılar
γ	RBF kernel genişlik parametresi
η	Öğrenme oranı
λ	XGBoost L2 düzenleme parametresi
ξ	DVM gevşek değişkeni
$\bar{\rho}$	Ağaçlar arası ortalama korelasyon
$\sigma(z)$	Sigmoid fonksiyonu
$\Omega(h)$	XGBoost model karmaşıklık terimi

KISALTMA LİSTESİ

AUC	Eğri Altındaki Alan (Area Under the Curve)
DN	Doğru Negatif
DP	Doğru Pozitif
DPO	Doğru Pozitif Oranı
DVM	Destek Vektör Makinesi
F1	F1-Skoru
KNN	K-En Yakın Komşu (K-Nearest Neighbors)
LR	Lojistik Regresyon (Logistic Regression)
RBF	Radyal Tabanlı Fonksiyon (Radial Basis Function)
RF	Random Forest (Rastgele Orman)
ROC	Alıcı İşletim Karakteristiği (Receiver Operating Characteristic)
SMOTE	Sentetik Azınlık Örneklem Arttırma Yöntemi (Synthetic Minority Oversampling Technique)
UCI	University of California Irvine
XGBoost	Gradyan Artırma (Extreme Gradient Boosting)
YN	Yanlış Negatif
YP	Yanlış Pozitif
YPO	Yanlış Pozitif Oranı

ŞEKİL LİSTESİ

Şekil 6.1	Modeller Arası ROC Eğrisi Karşılaştırması.....	16
Şekil 6.2	XGBoost Karmaşıklık Matrisi.....	17
Şekil 6.3	XGBoost Öznitelik Önem Grafiği.....	18
Şekil 6.4	Sayısal Öznitelikler Arası Korelasyon Analizi.....	19

TABLO LİSTESİ

Tablo 4.1	Adult Veri Setinin Temel Özellikleri.....	9
Tablo 4.2	Kullanılan Algoritmaların Parametre Değerleri.....	11
Tablo 5.1	Performans Metriklerinin Karşılaştırmalı Özeti.....	14
Tablo 6.1	Algoritmaların Çapraz Doğrulama Performans Sonuçları.....	15

ÖNSÖZ

Yapay zekâ ve makine öğrenmesi, günümüzde neredeyse her alanda köklü dönüşümlere yol açmaktadır. Sağlıktan finansa, eğitimden güvenliğe uzanan geniş bir yelpazede veri odaklı karar alma mekanizmaları giderek daha fazla önem kazanmaktadır. Bu dönüşümün merkezinde yer alan sınıflandırma algoritmaları, ham veriden anlamlı örüntüler çıkarma kapasiteleriyle modern veri biliminin temel yapı taşlarından birini oluşturmaktadır.

Bu çalışma, ikili sınıflandırma problemlerinde yaygın olarak kullanılan dört farklı makine öğrenmesi algoritmasının karşılaştırmalı performans analizini konu almaktadır. Yalnızca teorik bir değerlendirme sunmakla yetinilmeyip gerçek dünya verisi üzerinde uygulama gerçekleştirilmiş, elde edilen sonuçlar çok boyutlu bir bakış açısıyla yorumlanmıştır. Bu yaklaşımın, konuya ilgi duyan araştırmacılara ve öğrencilere faydalı bir kaynak oluşturmasını umuyorum.

Tez sürecinin her aşamasında değerli katkılarını ve yönlendirmelerini esirgemeyen danışman hocam Doç. Dr. Müslüm Özışık'a, her koşulda yanımda olan aileme ve bu süreçte manevi desteklerini hissettiren tüm arkadaşlarıma içtenlikle teşekkür ederim.

ÖZET

Makine öğrenmesi algoritmalarının gerçek dünya problemlerine uygulanması ve bu algoritmaların birbirleriyle karşılaştırmalı olarak değerlendirilmesi, günümüz veri bilimi araştırmalarının önemli odak noktalarından birini oluşturmaktadır. Bu çalışmada, UCI Machine Learning Repository'den elde edilen Adult-Census Income veri seti üzerinde dört farklı makine öğrenmesi algoritmasının ikili sınıflandırma performansı karşılaştırmalı biçimde incelenmiştir. Çalışma kapsamında Lojistik Regresyon, Destek Vektör Makinesi, Random Forest ve XGBoost algoritmaları ele alınmıştır.

48.842 örnek ve 14 öznitelik içeren veri seti; eksik değer temizleme, gereksiz öznitelik çıkarma, MinMaxScaler ile sayısal ölçeklendirme ve One-Hot Encoding ile kategorik dönüşüm adımlarını kapsayan sistematik bir ön işleme sürecinden geçirilmiştir. Veri setinde gözlemlenen yaklaşık %75-25 oranındaki sınıf dengesizliğini gidermek amacıyla SMOTE yöntemi, veri sızıntısını önleyecek biçimde pipeline mimarisi içine entegre edilmiştir. Model değerlendirmesi 10 katlı tabakalı çapraz doğrulama yöntemiyle gerçekleştirilmiş; doğruluk, kesinlik, duyarlılık, F1-skoru ve ROC-AUC olmak üzere beş farklı performans metriği kullanılmıştır.

Deneysel sonuçlar incelendiğinde XGBoost algoritmasının doğruluk (0.8539), kesinlik (0.6715), F1-skoru (0.7176) ve ROC-AUC (0.9227) metriklerinde en yüksek performansı sergilediği görülmüştür. Lojistik Regresyon ise duyarlılık metriğinde (0.8462) ve ROC-AUC değerinde (0.9050) güçlü bir performans ortaya koyarak yorumlanabilirliği ve hesaplama verimliliği sayesinde önemli bir alternatif model konumunu korumuştur. Random Forest dengeli bir kesinlik-duyarlılık profili sergilerken Destek Vektör Makinesi, büyük veri setlerindeki eğitim süresi dezavantajına ek olarak doğruluk ve kesinlik metriklerinde görece düşük sonuçlar üretmiştir. Sayısal öznitelikler arasında gerçekleştirilen korelasyon analizi, değişkenler arasında anlamlı bir doğrusal ilişki bulunmadığını ortaya koymuş ve her özniteliğin modele bağımsız katkı sağladığını doğrulamıştır.

Bu çalışma, aynı veri seti ve deneysel kurulum üzerinde çok metrikli karşılaştırma yapılmasının ve SMOTE'un pipeline içine entegre edilmesinin metodolojik önemine dikkat çekmekte; benzer ikili sınıflandırma problemleri için pratik bir referans sunmaktadır.

Anahtar Kelimeler: Makine öğrenmesi, İkili sınıflandırma, XGBoost, Destek Vektör Makinesi, Random Forest, Lojistik Regresyon, SMOTE, ROC-AUC, Çapraz doğrulama, Adult veri seti

ABSTRACT

The application of machine learning algorithms to real-world problems and their comparative evaluation have become one of the key research focuses in contemporary data science. In this study, the binary classification performance of four different machine learning algorithms was comparatively examined on the Adult-Census Income dataset obtained from the UCI Machine Learning Repository. The algorithms investigated in this study include Logistic Regression, Support Vector Machine, Random Forest, and XGBoost.

The dataset, comprising 48,842 instances and 14 features, was subjected to a systematic preprocessing pipeline including missing value removal, elimination of redundant features, numerical scaling via MinMaxScaler, and categorical encoding through One-Hot Encoding. To address the observed class imbalance of approximately 75-25 percent, the SMOTE method was integrated into the pipeline architecture to prevent data leakage. Model evaluation was conducted using 10-fold stratified cross-validation, and five performance metrics were employed: accuracy, precision, recall, F1-score, and ROC-AUC.

Experimental results demonstrated that the XGBoost algorithm achieved the highest performance in terms of accuracy (0.8539), precision (0.6715), F1-score (0.7176), and ROC-AUC (0.9227). Logistic Regression exhibited strong performance in recall (0.8462) and ROC-AUC (0.9050), maintaining its position as a significant alternative model due to its interpretability and computational efficiency. Random Forest demonstrated a balanced precision-recall profile, while the Support Vector Machine produced comparatively lower results in accuracy and precision metrics, further constrained by its extended training time on large-scale datasets. Correlation analysis conducted among numerical features revealed no significant linear relationship between variables, confirming that each feature contributes independent information to the models.

This study highlights the methodological importance of multi-metric comparison on the same dataset and experimental setup, as well as the integration of SMOTE within the pipeline architecture, providing a practical reference for similar binary classification problems.

Keywords: Machine learning, Binary classification, XGBoost, Support Vector Machine, Random Forest, Logistic Regression, SMOTE, ROC-AUC, Cross-validation, Adult dataset

1.GİRİŞ

Günümüzde veri üretiminin hızla artmasıyla birlikte bu verilerden anlamlı bilgi çıkarma ihtiyacı da beraberinde büyümektedir. Makine öğrenmesi, bilgisayar sistemlerinin açık bir programlama yapılmadan geçmiş deneyimler ve veriler aracılığıyla öğrenmesini ve karar vermesini sağlayan yapay zekanın en önemli alt dallarından biri olarak öne çıkmaktadır [1]. Makine öğrenmesi yöntemleri; örüntü tanıma, görüntü sınıflandırma, doğal dil işleme, tıbbi teşhis ve risk analizi gibi birbirinden farklı alanlarda başarıyla uygulanmaktadır [2].

Makine öğrenmesi problemleri genel olarak gözetimli öğrenme, gözetimsiz öğrenme ve pekiştirmeli öğrenme olmak üzere üç ana başlık altında incelenmektedir. Gözetimli öğrenme kapsamında ele alınan sınıflandırma problemleri, bir girdinin önceden tanımlanmış sınıflardan birine atanması işlemi olarak tanımlanmaktadır [1]. Bu problemlerin yalnızca iki çıktı sınıfı içerdiği özel durum ise ikili sınıflandırma olarak adlandırılmaktadır. İkili sınıflandırma; hastalık teşhisi (hasta/sağlıklı), spam tespiti (spam/ham), kredi risk değerlendirmesi (onaylı/reddedildi) ve kimlik hırsızlığı tespiti gibi gerçek dünya problemlerinde yaygın biçimde kullanılmaktadır [3, 4].

Literatürde ikili sınıflandırma problemlerine yönelik pek çok makine öğrenmesi algoritması geliştirilmiş ve uygulanmıştır. Lojistik Regresyon, doğrusal sınıflandırılabilir problemlerde sadeliği ve yorumlanabilirliğiyle öne çıkan temel bir referans model olarak kabul edilmektedir [3]. Destek Vektör Makinesi, sınıflar arasındaki ayrım marjini en büyükleyen hiperdüzlemler aracılığıyla hem doğrusal hem de doğrusal olmayan problemlerde yüksek genelleme başarısı sunmaktadır [5]. Random Forest, birden fazla karar ağacını bir araya getiren topluluk öğrenme yaklaşımı sayesinde aşırı uyum sorununa karşı dirençli ve doğru sonuçlar üretmektedir [6]. XGBoost ise gradyan arttırma yönteminin ölçeklenebilir ve optimize edilmiş bir uygulaması olup özellikle büyük veri kümelerinde hız ve doğruluk avantajıyla dikkat çekmektedir [7].

Algoritmaların performansını karşılaştırmak için standart değerlendirme metriklerine başvurulması gerekmektedir. Bu bağlamda doğruluk, kesinlik, duyarlılık, F1-skoru ve ROC eğrisi altındaki alan (AUC) en sık kullanılan ölçütler arasında yer almaktadır [8]. Özellikle sınıf dengesizliği içeren veri setlerinde yalnızca doğruluk metriğine dayanan değerlendirmeler yanıltıcı sonuçlar doğurabilmekte; bu nedenle çok metrikli karşılaştırma yaklaşımı tercih edilmektedir [8].

Bu çalışmada, UCI Machine Learning Repository'de kamuya açık olarak sunulan Adult-Census Income veri seti üzerinde dört farklı makine öğrenmesi algoritmasının ikili sınıflandırma performansı karşılaştırmalı biçimde incelenmektedir. 48.842 örnek ve 14 öznitelik içeren bu veri setinde hedef değişken, bir bireyin yıllık gelirinin 50.000 doları aşp aşmadığıdır [9]. Veri setinin gerçek dünya niteliği taşıması, eksik değerler ve kategorik değişkenler içermesi ile sınıf dengesizliği barındırması, onu karşılaştırmalı çalışmalar için uygun bir zemin haline getirmektedir.

Çalışma kapsamında incelenen algoritmalar şunlardır: Lojistik Regresyon, Destek Vektör Makinesi, Random Forest ve XGBoost. Model eğitimi ve değerlendirme sürecinde veri sızıntısını önlemek amacıyla SMOTE tabanlı sınıf dengeleme işlemi pipeline yapısı içine alınmış, 10 katlı tekrarlı tabakalı çapraz doğrulama yöntemi kullanılmıştır [10].

Tezin geri kalan bölümleri şu şekilde düzenlenmiştir: İkinci bölümde bu alanda yapılmış literatür çalışmaları incelenmektedir. Üçüncü bölümde kullanılan algoritmaların matematiksel ve teorik temelleri açıklanmaktadır. Dördüncü bölümde veri seti, ön işleme adımları ve uygulanan metodoloji aktarılmaktadır. Beşinci bölümde değerlendirme metrikleri tanıtılmaktadır. Altıncı bölümde elde edilen bulgular tablo ve grafiklerle sunulmakta, yedinci bölümde ise sonuçlar ve gelecek çalışma önerileri yer almaktadır.

2. LİTERATÜR TARAMASI

İkili sınıflandırma problemlerinde makine öğrenmesi algoritmalarının karşılaştırmalı olarak değerlendirilmesi, son yıllarda giderek artan bir ilgi görmektedir. Bu bölümde, çalışmada kullanılan algoritmalar ve değerlendirme yöntemleriyle doğrudan ilgili literatür çalışmaları incelenmektedir.

2.1. Sınıflandırma Algoritmalarının Tarihsel Gelişimi

Makine öğrenmesi alanındaki sınıflandırma algoritmalarının temelleri, 1950'li yıllara kadar uzanmaktadır. Bu dönemde bilgisayarların öğrenme kapasitesine sahip olup olamayacağı sorusu araştırmacıları meşgul etmiş; bu merak, istatistiksel öğrenme yöntemlerinin doğuşuna zemin hazırlamıştır [1]. 1967 yılında K-En Yakın Komşu algoritmasının geliştirilmesiyle örüntü tanıma alanında önemli bir adım atılmış; ardından Karar Ağaçları, veriyi hiyerarşik bölme mantığıyla sınıflandıran ilk sezgisel yöntemler arasına girmiştir [1].

1980'li yıllar, uzman sistemlerin yükselişine sahne olmuştur. Bu dönemde kurallar veriden değil, alan uzmanlarından manuel olarak elde edilmekteydi. Ancak ölçeklenebilirlik sorunları ve uyum güçlükleri, araştırmacıları istatistiksel öğrenme yöntemlerine yöneltmiştir. 1980'lerin ortasında geri yayılım algoritmasının yeniden keşfedilmesiyle yapay sinir ağları canlanmış; bu gelişme modern derin öğrenmenin habercisi olmuştur [1].

1990'lı yıllar ise sınıflandırma algoritmalarının altın çağı olarak değerlendirilebilir. Bu dönemin en önemli kırılma noktalarından biri, Cortes ve Vapnik [5] tarafından 1995 yılında geliştirilen Destek Vektör Makinesi'nin yayımlanmasıdır. Marjın maksimizasyonu ilkesine dayanan bu algoritma hem doğrusal hem de doğrusal olmayan problemlerde üstün genelleme başarısı sunarak kısa sürede en etkili sınıflandırma yöntemlerinden biri haline gelmiştir. Yine aynı yıl Tin Kam Ho tarafından rassal karar ormanlarının temelleri atılmış; bu fikir Breiman [6] tarafından 2001 yılında Random Forest adıyla kapsamlı biçimde formüle edilmiştir. Random Forest, birden fazla karar ağacını torbalama yöntemiyle bir araya getirerek tek ağaçların aşırı uyum sorununu başarıyla aşmıştır.

Lojistik Regresyon ise çok daha köklü bir geçmişe sahiptir. İstatistik literatüründe onlarca yıldır kullanılan bu yöntem, makine öğrenmesi topluluğunda ikili sınıflandırma için temel referans model konumunu korumuştur. Sigmoid fonksiyonu aracılığıyla olasılıksal çıktılar üretmesi ve yorumlanabilirliği, onu günümüzde de geçerliliğini sürdüren bir algoritma yapmaktadır [3].

2000'li yılların başında topluluk öğrenme yöntemlerine olan ilgi hız kazanmıştır. AdaBoost ile başlayan bu süreç, Gradyan Arttırma makinelerinin geliştirilmesiyle ivme kazanmış; 2014 yılından itibaren özellikle Kaggle yarışmalarında elde edilen başarılarla birlikte XGBoost ön plana çıkmaya başlamıştır. Chen ve Guestrin [7] tarafından 2016 yılında yayımlanan XGBoost makalesi, gradyan arttırma yöntemini

ölçeklenebilir ve hızlı bir sisteme dönüştürerek alanın en etkili algoritmalarından biri haline gelmesini sağlamıştır.

Sınıf dengesizliği sorunu ise uzun yıllar boyunca sınıflandırma performansını olumsuz etkileyen kritik bir problem olarak gündemde kalmıştır. Bu soruna yönelik en etkili çözümlerden biri olan SMOTE, Chawla ve diğerleri [10] tarafından 2002 yılında geliştirilmiştir. Azınlık sınıfına ait sentetik örnekler üreterek sınıf dağılımını dengeleyen bu yöntem, dengesiz veri setleriyle çalışan araştırmacılar için standart bir ön işleme aracı haline gelmiştir.

2.2. İkili Sınıflandırmada Karşılaştırmalı Çalışmalar

Makine öğrenmesi algoritmalarının karşılaştırmalı değerlendirilmesi, literatürde geniş bir yer tutmaktadır. Bu çalışmaların ortak amacı, farklı algoritmaların belirli veri setleri ve problem türleri üzerindeki göreceli üstünlüklerini ve zayıflıklarını sistematik biçimde ortaya koymaktır.

Baktır ve Atay [3], spam e-posta sınıflandırma probleminde Naive Bayes, Lojistik Regresyon, Karar Ağacı ve K-En Yakın Komşu algoritmalarını beş farklı veri seti üzerinde karşılaştırmıştır. Çalışmada doğruluk, kesinlik, duyarlılık ve F1-skoru metrikleri kullanılmış; Lojistik Regresyon'un genel olarak en tutarlı sonuçları ürettiği gözlemlenmiştir. Özellikle Enron 5 veri setinde %99,42 doğruluk oranına ulaşılmış; spam oranının yüksek olduğu veri setlerinde sınıflandırma başarısının arttığı da aynı çalışmada vurgulanmıştır [3].

Güvenç ve diğerleri [4], öğrenci başarı tahminine yönelik gerçekleştirdikleri çalışmada küçük ve dengesiz bir veri seti üzerinde altı farklı makine öğrenmesi algoritmasını karşılaştırmıştır. Veri yetersizliğini gidermek amacıyla Chawla ve diğerleri [10] tarafından geliştirilen SMOTE yöntemi uygulanmış; SMOTE sonrasında K-En Yakın Komşu algoritmasının %97,66 doğrulukla en başarılı sonucu verdiği görülmüştür. Bu çalışma, sınıf dengesizliğinin model performansı üzerindeki olumsuz etkisini ve SMOTE'un bu sorunu gidermekteki etkinliğini açıkça ortaya koymaktadır [4].

Kalaycı [2], kimlik hırsız web sitelerinin tespitine yönelik gerçekleştirdiği çalışmada yedi farklı algoritmayı 1353 örnekten oluşan bir veri seti üzerinde karşılaştırmıştır. Eğitim/test ayrımı yapılan deneylerde Random Forest en yüksek doğruluğa (0,8793) ulaşırken, çapraz doğrulama kullanıldığında Çok Katmanlı Algılayıcı öne çıkmıştır. Söz konusu çalışma, deney kurulumunun algoritma sıralaması üzerinde belirleyici bir etkiye sahip olduğunu göstermesi bakımından önem taşımaktadır [2].

Abdullah ve Abdulazeez [11], 2016-2020 yılları arasında yayımlanmış çalışmaları kapsayan kapsamlı bir incelemede Cortes ve Vapnik [5] tarafından geliştirilen Destek Vektör Makinesi'nin farklı alanlardaki uygulamalarını ele almıştır. İncelenen çalışmaların büyük çoğunluğunda DVM'nin diğer algoritmalara kıyasla yüksek

doğruluk değerleri elde ettiği görülmüş; yüz tanıma alanında %97,47, kanser tespitinde ise %97 doğruluğa ulaşıldığı raporlanmıştır [11].

Bentejac ve diğerleri [12], Chen ve Guestrin [7] tarafından geliştirilen XGBoost'u Random Forest ve Gradyan Artırma yöntemleriyle UCI veri havuzundan derlenen 28 farklı veri seti üzerinde karşılaştırmıştır. Ayarlanmış XGBoost'un ortalama sıralama bakımından en iyi performansı sergilediği, ancak bu üstünlüğün istatistiksel olarak anlamlı olmadığı görülmüştür. Ayrıca XGBoost'un eğitim hızı açısından Gradyan Artırma'dan yaklaşık 3,5 kat daha hızlı olduğu belirlenmiştir [12].

Pandey ve diğerleri [1], makine öğrenmesi algoritmalarını genel hatlarıyla ele aldıkları çalışmalarında gözetimli, gözetimsiz ve pekiştirmeli öğrenme yöntemlerini incelemiştir. Söz konusu çalışma, makine öğrenmesinin tarihsel gelişimi ve temel algoritmalar hakkında kapsamlı bir genel bakış sunmaktadır [1]. Liu ve diğerleri [13], Breiman [6] tarafından tanımlanan Random Forest algoritmasının teorik temellerini ve uygulama alanlarını incelemiş; aşırı uyum sorununu çözmedeki etkinliğini ve gürültüye karşı dayanıklılığını ortaya koymuştur [13]. Berrar [8] ise ikili sınıflandırma performans metriklerini kapsamlı biçimde ele almış; özellikle sınıf dengesizliği içeren veri setlerinde yalnızca doğruluk metriğine güvenilmemesi gerektiğini vurgulamıştır [8].

3.TEORİK ALTYAPI VE ALGORİTMALAR

Bu bölümde çalışmada kullanılan dört makine öğrenmesi algoritmasının matematiksel temelleri ve çalışma prensipleri açıklanmaktadır.

3.1. Logistik Regresyon

Lojistik Regresyon, adındaki "regresyon" ifadesine karşın özünde bir sınıflandırma algoritmasıdır. İkili sınıflandırma problemlerinde bir örneğin belirli bir sınıfa ait olma olasılığını modellemek amacıyla kullanılmakta ve endüstride yaygın biçimde tercih edilmektedir [3]. Algoritmanın temel yapısı, doğrusal regresyonun çıktısını sigmoid fonksiyonu aracılığıyla $[0, 1]$ aralığına sıkıştırmaya dayanmaktadır.

Sigmoid fonksiyonu aşağıdaki gibi tanımlanmaktadır:

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (3.1)$$

Burada z , giriş öznelikleri ile ağırlıkların doğrusal kombinasyonunu ifade etmektedir:

$$z = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k \quad (3.2)$$

İkili sınıflandırma için pozitif sınıfa ait olma olasılığı şu şekilde hesaplanmaktadır:

$$z = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k \quad (3.3)$$
$$P(Y = 1|X) = \frac{1}{(1 + e^{-z})}$$

Model parametreleri, binom log-olasılık fonksiyonu maksimize edilerek tahmin edilmektedir:

$$L(\beta) = \sum_{i=1}^n [y_i \log P_i + (1 - y_i) \log(1 - P_i)] \quad (3.4)$$
$$P_i = P(Y = 1|X_i)$$

Tahmin edilen olasılık değeri belirli bir eşik değerinin (genellikle 0,5) üzerinde ise örnek pozitif sınıfa, aksi hâlde negatif sınıfa atanmaktadır. Lojistik Regresyon, doğrusal olarak ayrılabilir sınıflarda yüksek performans sergilemekte; yorumlanabilirliği ve hesaplama verimliliği sayesinde karşılaştırmalı çalışmalarda temel referans model olarak sıkça kullanılmaktadır [4].

3.2. Destek Vektör Makinesi

DVM, Cortes ve Vapnik [5] tarafından geliştirilen ve istatistiksel öğrenme teorisine dayanan denetimli bir makine öğrenmesi algoritmasıdır. Algoritmanın temel amacı, farklı sınıflara ait veri noktaları arasındaki ayrım marjini en büyükleyen hiperdüzlemi bulmaktır. Marjin, hiperdüzleme en yakın konumdaki eğitim örneklerine olan mesafe olarak tanımlanmakta; bu örnekler ise destek vektörleri olarak adlandırılmaktadır. Doğrusal olarak ayrılabilir iki sınıf için hiperdüzlem şu şekilde ifade edilmektedir:

$$w \cdot x + b = 0 \quad (3.5)$$

Burada w ağırlık vektörünü, x girdi vektörünü ve b önyargı terimini göstermektedir. Marjini en büyükleyen optimizasyon problemi şu şekilde formüle edilmektedir:

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad (3.6)$$

Koşul:

$$y_i(w \cdot x_i + b) \geq 1, \forall i$$

Verilerin doğrusal olarak ayrılamadığı durumlarda gevşek değişkenler $\xi_i \geq 0$ eklenerek yumuşak marjin formülasyonuna geçilmektedir:

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad (3.7)$$

Koşul:

$$y_i(w \cdot x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

Burada C parametresi marjin genişliği ile sınıflandırma hatası arasındaki dengeyi kontrol etmektedir. Doğrusal olmayan problemlerde ise kernel fonksiyonları aracılığıyla veri daha yüksek boyutlu bir özellik uzayına taşınmaktadır. En yaygın kullanılan RBF kernel'i şu şekilde tanımlanmaktadır:

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2) \quad (3.8)$$

DVM'nin genelleme hatası düşük olmakla birlikte, büyük veri setlerinde eğitim süresi belirgin biçimde uzayabilmekte ve uygun kernel ile parametre seçimi kritik önem taşımaktadır [11].

3.3. Random Forest

Random Forest, Breiman [6] tarafından 2001 yılında tanımlanan ve karar ağaçlarından oluşan bir topluluk öğrenme yöntemidir. Algoritma, eğitim verisi üzerinde torbalama yöntemiyle oluşturulan birbirinden bağımsız karar ağaçlarının tahminlerini çoğunluk oyu ilkesiyle birleştirerek nihai sınıfı belirlemektedir.

Random Forest karar fonksiyonu şu şekilde ifade edilmektedir:

$$H(x) = \arg \max_Y \sum_{k=1}^K I(h_k(x) = Y) \quad (3.9)$$

Burada $H(x)$ topluluk modelinin çıktısını, h_k k'ncı karar ağacını, K toplam ağaç sayısını ve $I(\cdot)$ gösterge fonksiyonunu temsil etmektedir [13]. Her karar ağacı, düğüm bölmelerinde Gini safsızlık indeksi veya bilgi kazancı ölçütünü kullanmaktadır. Gini safsızlık indeksi şu şekilde hesaplanmaktadır:

$$Gini(t) = 1 - \sum_{c=1}^c p(c|t)^2 \quad (3.10)$$

Burada $p(c|t)$, t düğümündeki c sınıfına ait örneklerin oranını ifade etmektedir. Modelin genelleme hatası için üst sınır şu şekilde ifade edilmektedir [6]:

$$PE^* \leq \frac{\bar{\rho}(1 - s^2)}{s^2} \quad (3.11)$$

Burada s bireysel ağaçların gücünü, $\bar{\rho}$ ise ağaçlar arasındaki ortalama korelasyonu göstermektedir. Bu eşitsizlik, güçlü ve birbirleriyle düşük korelasyonlu ağaçların daha iyi bir topluluk modeli oluşturduğunu matematiksel olarak ortaya koymaktadır. Torbalama prosedürünün doğal bir yan ürünü olarak ortaya çıkan torba dışı örnekler, modelin genelleme hatasının ayrı bir test seti gerektirmeksizin tahmin edilmesine olanak tanımaktadır [6].

3.4. XGBoost

XGBoost, Chen ve Guestrin [7] tarafından geliştirilen ve gradyan arttırma yönteminin yüksek ölçeklenebilirlik odaklı bir uygulamasıdır. Gradyan arttırma yönteminde olduğu gibi XGBoost da zayıf öğrencileri ardışık biçimde bir araya getirmektedir. m'inci adımda model şu şekilde güncellenmektedir:

$$F_m(x) = F_{m-1}(x) + \eta \cdot h_m(x) \quad (3.12)$$

Burada η öğrenme oranını, $h_m(x)$ ise m'inci zayıf öğrenciyi (sığ karar ağacı) ifade etmektedir. XGBoost'un diğer gradyan arttırma yöntemlerinden temel farkı, hem kayıp

fonksiyonunu hem de model karmaşıklığını aynı anda kontrol eden özelleştirilmiş bir hedef fonksiyonu kullanmasıdır:

$$L^{(m)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(m)}) + \sum_{k=1}^m \Omega(h_k) \quad (3.13)$$

Karmaşıklık terimi Ω şu şekilde tanımlanmaktadır:

$$\Omega(h) = \gamma T + \frac{1}{2} \lambda \|w\|^2 \quad (3.14)$$

Burada T yaprak sayısını, w yaprak çıktı skorlarını, γ minimum kayıp azalma eşiğini ve λ L2 düzenleme parametresini ifade etmektedir [7]. İkinci dereceden Taylor açılımı uygulandıktan sonra t 'inci ağacın j 'inci yaprağı için optimal ağırlık değeri şu şekilde elde edilmektedir:

$$w_j^* = - \frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda} \quad (3.15)$$

Burada g_i birinci türev (gradient), h_i ise ikinci türev (Hessian) değerlerini göstermektedir. Bu formülasyon, ağaçların bölünme kriterini doğrudan etkileyerek ön budama stratejisi oluşturmada ve gereksiz karmaşıklığın önüne geçmektedir. Bentejac ve diğerlerinin [12] 28 veri seti üzerinde gerçekleştirdiği karşılaştırmada XGBoost, tek model eğitim süresi bakımından Random Forest 'dan yaklaşık 3,5 kat, Gradyan Arttırma'dan ise 2,4 ila 4,3 kat daha hızlı olduğu saptanmıştır.

4. METODOLOJİ VE UYGULAMA

Bu bölümde çalışmanın metodolojik çerçevesi ayrıntılı biçimde ele alınmaktadır. Kullanılan veri setinin özellikleri, uygulanan ön işleme adımları, sınıf dengesizliğinin giderilme yöntemi, pipeline mimarisi ve değerlendirme yaklaşımı sırasıyla açıklanmaktadır.

4.1. Veri Setinin Tanıtılması

Bu çalışmada UCI Machine Learning Repository'de kamuya açık olarak sunulan Adult-Census Income veri seti kullanılmıştır [9]. Veri seti, Barry Becker tarafından 1994 yılı ABD Nüfus Sayımı veritabanından çıkarılmış olup Becker ve Kohavi tarafından makine öğrenmesi topluluğuna kazandırılmıştır. Temel sınıflandırma görevi, bir bireyin demografik ve sosyoekonomik özelliklerine dayanarak yıllık gelirinin 50.000 doları aşp aşmadığının tahmin edilmesidir.

Veri seti toplamda 48.842 örnek ve 14 öznitelik içermektedir. Öznitelikler sayısal ve kategorik olmak üzere iki türde bulunmaktadır. Yaş, eğitim süresi, sermaye kazancı, sermaye kaybı ve haftalık çalışma saati sayısal öznitelikleri oluştururken; çalışma sınıfı, medeni durum, meslek, akrabalık ilişkisi, ırk, cinsiyet ve ülke kategorik öznitelikler arasında yer almaktadır. Hedef değişken ikili yapıdadır: geliri 50.000 doların altında kalanlar 0, üzerinde olanlar ise 1 olarak kodlanmıştır. Veri setinin genel özellikleri Tablo 4.1'de özetlenmektedir.

Tablo 4.1. Adult Veri Setinin Temel Özellikleri

Özellik	Değer
Toplam Örnek Sayısı	48.842
Öznitelik Sayısı	14
Sayısal Öznitelik Sayısı	6
Kategorik Öznitelik Sayısı	8
Eksik Değer	Var (workclass, occupation)
Hedef Sınıf Dağılımı ($\leq 50K$ / $> 50K$)	$\sim 75\%$ / $\sim 25\%$

4.2. Veri Ön İşleme

Ham verinin modelleme sürecine hazır hale getirilmesi amacıyla sıralı ön işleme adımları uygulanmıştır.

Eksik Değerlerin Giderilmesi: Veri setinde workclass ve occupation sütunlarında eksik değerler bulunmaktadır. Bu değerler "?" karakteriyle işaretlenmiş olup ilgili satırlar analizden çıkarılmıştır. Eksik değer içeren satırların silinmesi, öznitelik dağılımlarını belirgin biçimde bozmayan ve literatürde yaygın kabul gören bir yaklaşımdır [3].

Gereksiz Özniteliklerin Çıkarılması: education sütunu, education-num sütunuyla aynı bilgiyi ordinal biçimde taşıdığından bilgi tekrarını önlemek amacıyla veri setinden çıkarılmıştır. Benzer şekilde fnlwgt sütunu, nüfus sayımına özgü istatistiksel bir ağırlık faktörü olduğundan sınıflandırma açısından anlamlı bir katkı sunmamakta ve bu nedenle analizin dışında bırakılmıştır.

Öznitelik Ölçeklendirme: Sayısal öznitelikler, mesafeye dayalı hesaplamalar gerçekleştiren Destek Vektör Makinesi algoritmasının tutarlı sonuçlar üretebilmesi için MinMaxScaler yöntemiyle [0, 1] aralığına ölçeklendirilmiştir. MinMaxScaler dönüşümü şu şekilde tanımlanmaktadır [2]:

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}} \quad (4.1)$$

Kategorik Değişken Dönüşümü: Kategorik öznitelikler, makine öğrenmesi algoritmalarının sayısal girdi beklentisini karşılamak amacıyla One-Hot Encoding yöntemiyle dönüştürülmüştür. Eğitim setinde görülmeyen kategorilerin test aşamasında hata oluşturmaması için handle_unknown='ignore' parametresi kullanılmıştır.

4.3. Sınıf Dengesizliğinin Giderilmesi

Adult veri setinde hedef sınıflar arasında belirgin bir dengesizlik bulunmaktadır: örneklerin yaklaşık %75'i $\leq 50K$, %25'i ise $> 50K$ sınıfına aittir. Bu dengesizlik, modellerin azınlık sınıfını göz ardı ederek çoğunluk sınıfına yönelmesine ve yanıltıcı yüksek doğruluk değerleri üretmesine neden olabilmektedir [8].

Bu sorunu gidermek amacıyla SMOTE yöntemi uygulanmıştır [10]. SMOTE, azınlık sınıfına ait gerçek örnekler arasında doğrusal enterpolasyon yaparak sentetik yeni örnekler üretmektedir. Sentetik örnek üretim formülü şu şekilde tanımlanmaktadır [10]:

$$x_{new} = x_i + \lambda \cdot (x_{zi} - x_i) \quad (4.2)$$

Burada x_i azınlık sınıfından seçilen bir örneği, x_{zi} bu örneğin K-en yakın komşularından birini ve $\lambda \in [0,1]$ aralığında seçilen rastgele bir sayıyı ifade etmektedir. Veri sızıntısını önlemek amacıyla kritik bir tasarım kararı olarak SMOTE, ön işleme ve model eğitimi kapsayan pipeline yapısının içine entegre edilmiştir. Bu sayede sentetik örnekler yalnızca her çapraz doğrulama katının eğitim bölümüne uygulanmakta, test bölümü ise her zaman gerçek veriden oluşmaktadır [4].

4.4. Pipeline Mimarisi

Tüm ön işleme ve modelleme adımları, scikit-learn ve imbalanced-learn kütüphaneleri kullanılarak tek bir pipeline yapısı altında birleştirilmiştir. Her model için pipeline üç aşamadan oluşmaktadır: (1) ColumnTransformer ile sayısal ve kategorik özniteliklerin

ayrı ayrı işlenmesi, (2) SMOTE ile sınıf dengeleme ve (3) ilgili sınıflandırıcının eğitimi. Bu mimari, her çapraz doğrulama katında ön işleme parametrelerinin yalnızca eğitim verisinden öğrenilmesini garanti altına almaktadır.

4.5. Model Parametreleri

Çalışmada dört algoritma için kullanılan temel parametre değerleri Tablo 4.2'de sunulmaktadır.

Tablo 4.2. Kullanılan Algoritmaların Parametre Değerleri

Algoritma	Temel Parametreler
Lojistik Regresyon	max_iter=1000
Destek Vektör Makinesi	probability=True, kernel=RBF
Random Forest	n_estimators=200, random_state=42
XGBoost	eval_metric='logloss', random_state=42

4.6. Değerlendirme Yöntemi

Model performansları, 10 katlı Tekrarlı Tabakalı Çapraz Doğrulama yöntemiyle değerlendirilmiştir. Bu yöntemde veri seti, hedef sınıf dağılımı korunacak şekilde rastgele 10 eşit parçaya bölünmekte; her seferinde 9 parça eğitim, 1 parça test için kullanılmaktadır. Tabakalı örnekleme, her katta sınıf oranlarının orijinal veriyle tutarlı kalmasını sağlamaktadır [2]. Her algoritma için raporlanan metrik değerleri 10 katın ortalama sonuçlarını yansıtmaktadır:

$$\bar{m} = \frac{1}{K} \sum_{k=1}^K m_k \quad (4.3)$$

Burada $\bar{m}$ ortalama metrik değerini, K kat sayısını (10) ve m_k k'nci kattaki metrik değerini ifade etmektedir.

5. PERFORMANS METRİKLERİ

Sınıflandırma modellerinin başarısını tek bir ölçüt üzerinden değerlendirmek, özellikle sınıf dengesizliği içeren veri setlerinde yanıltıcı sonuçlara yol açabilmektedir [8]. Bu nedenle çalışmada birbirini tamamlayan beş farklı performans metriği kullanılmıştır. Tüm metrikler, ikili sınıflandırma sonuçlarını özetleyen karmaşıklık matrisi üzerine inşa edilmektedir.

5.1. Karmaşıklık Matrisi

Karmaşıklık matrisi, bir sınıflandırıcının tahmin sonuçlarını gerçek sınıf etiketleriyle sistematik biçimde karşılaştıran temel bir değerlendirme aracıdır [8]. İkili sınıflandırma için dört temel bileşenden oluşmaktadır:

- **Doğru Pozitif (DP):** Pozitif sınıfın doğru tahmin edildiği durumlar ($>50K$ olarak tahmin edilip gerçekten $>50K$)
- **Doğru Negatif (DN):** Negatif sınıfın doğru tahmin edildiği durumlar ($\leq 50K$ olarak tahmin edilip gerçekten $\leq 50K$)
- **Yanlış Pozitif (YP):** Negatif sınıfın pozitif olarak yanlış tahmin edildiği durumlar (Tip I Hata)
- **Yanlış Negatif (YN):** Pozitif sınıfın negatif olarak yanlış tahmin edildiği durumlar (Tip II Hata)

5.2. Doğruluk

Doğruluk, doğru sınıflandırılan örneklerin toplam örnek sayısına oranını ifade etmektedir [8]:

$$\text{Doğruluk} = \frac{DP + DN}{DP + DN + YP + YN} \quad (5.1)$$

Sınıf dağılımı dengeli veri setlerinde güvenilir bir ölçüt olmakla birlikte, dengesiz veri setlerinde çoğunluk sınıfına yönelik yanlılık nedeniyle tek başına yeterli bir gösterge olamamaktadır [8].

5.3. Kesinlik

Kesinlik, pozitif olarak tahmin edilen örnekler arasında gerçekten pozitif olanların oranını göstermektedir [8]:

$$\text{Kesinlik} = \frac{DP}{DP + YP} \quad (5.2)$$

Yanlış pozitif sayısının minimize edilmesinin kritik önem taşıdığı durumlarda, örneğin kredi onay sistemlerinde, kesinlik metriği ön plana çıkmaktadır.

5.4. Duyarlılık

Duyarlılık, gerçek pozitif örnekler arasında modelin doğru tespit edebildiklerinin oranını ifade etmektedir [8]:

$$Duyarlılık = \frac{DP}{DP + YN} \quad (5.3)$$

Yanlış negatif sayısının minimize edilmesinin öncelikli olduğu senaryolarda, örneğin hastalık tarama sistemlerinde, duyarlılık belirleyici metrik konumuna gelmektedir. Sınıf dengesizliği durumlarında SMOTE uygulamasının azınlık sınıfı üzerindeki etkisi en belirgin biçimde duyarlılık metriğinde gözlemlenmektedir [4].

5.5. F1- Skoru

F1-Skoru, kesinlik ve duyarlılığın harmonik ortalaması olarak hesaplanan bileşik bir metriktir [8]:

$$F1 = 2 \times \frac{Kesinlik \times Duyarlilik}{Kesinlik + Duyarlilik} \quad (5.4)$$

Harmonik ortalama kullanılması, iki metrikten birinin diğerine göre belirgin biçimde düşük olduğu durumlarda F1-Skorunun da düşük çıkmasını sağlamaktadır. Bu özellik, kesinlik ve duyarlılık arasındaki dengeyi tek bir sayıyla ifade etmeyi mümkün kılmakta ve özellikle dengesiz veri setlerinde doğruluk metriğine kıyasla daha bilgilendirici bir değerlendirme sunmaktadır [8].

5.6. ROC Eğrisi veAUC

ROC eğrisi, farklı sınıflandırma eşik değerleri için Doğru Pozitif Oranı ile Yanlış Pozitif Oranı arasındaki değiş tokuşu görsel olarak ortaya koymaktadır [8]. Bu oranı tanımlamak gerekirse:

$$YPO = \frac{YP}{YP + DN} \quad (5.5)$$

$$DPO = \frac{DP}{DP + YN} \quad (5.6)$$

Eğri altında kalan alan olan AUC bu ilişkiyi tek bir sayısal değerle özetlemektedir. AUC aşağıdaki integral ile ifade edilmektedir [8]:

$$AUC = \int_0^1 (DPO(YPO)d(YPO)) \quad (5.7)$$

AUC değeri 0,5 rastgele tahmini, 1,0 ise mükemmel sınıflandırmayı temsil etmektedir. Sınıf dengesizliğine görece dayanıklı bir metrik olması nedeniyle AUC, karşılaştırmalı çalışmalarda tercih edilen bir ölçüt konumundadır [8].

5.7. Metriklerin Karşılaştırılması

Metrik	Formül	Odak Noktası	Dengesiz Veri Uyumu
Doğruluk	$(DP+DN)/(DP+DN+YP+YN)$	Genel başarı	Düşük
Kesinlik	$DP / (DP+YP)$	YP minimizasyonu	Orta
Duyarlılık	$DP / (DP+YN)$	YN minimizasyonu	Yüksek
F1-Skoru	$2 \times (K \times D) / (K + D)$	K-D dengesi	Yüksek
ROC-AUC	$\int DPO d(YPO)$	Ayırt edici güç	Yüksek

Tablo 5.1. Performans Metriklerinin Karşılaştırmalı Özeti

Bu çalışmada sonuçlar her beş metrik üzerinden raporlanmış ve karşılaştırma tek bir metriğe indirgenmemiştir. Böylelikle algoritmaların farklı performans boyutlarındaki güçlü ve zayıf yönlerinin kapsamlı biçimde ortaya konulması hedeflenmiştir.

6. BULGULAR VE KARŞILAŞTIRMALI ANALİZ

Bu bölümde, Adult veri seti üzerinde dört farklı makine öğrenmesi algoritmasının 10 katlı tabakalı çapraz doğrulama ile elde edilen performans sonuçları sunulmakta ve karşılaştırmalı olarak yorumlanmaktadır.

6.1. Genel Performans Karşılaştırması

Dört algoritmanın tüm metrikler üzerindeki performansı Tablo 6.1'de özetlenmektedir.

Tablo 6.1. Algoritmaların Çapraz Doğrulama Performans Sonuçları

Algoritma	Doğruluk	Kesinlik	Duyarlılık	F1-Skoru	ROC-AUC
Lojistik Regresyon	0.8076	0.5675	0.8462	0.6793	0.9050
Destek Vektör Mak.	0.7945	0.5477	0.8448	0.6645	0.8971
Random Forest	0.8374	0.6546	0.6884	0.6709	0.8893
XGBoost	0.8539	0.6715	0.7707	0.7176	0.9227

Tablo incelendiğinde XGBoost'un doğruluk, kesinlik, F1-skoru ve ROC-AUC metriklerinde diğer tüm algoritmaları geride bıraktığı görülmektedir. Duyarlılık metriğinde ise en yüksek değere Lojistik Regresyon ulaşmıştır. Bu durum, algoritmaların farklı performans boyutlarında birbirinden ayrılan güçlü yönleri sahip olduğuna işaret etmekte ve çok metrikli değerlendirme yaklaşımının gerekliliğini bir kez daha ortaya koymaktadır [8].

6.2. Doğruluk ve F1-Skoru Analizi

Doğruluk metriği açısından algoritmaların sıralaması şu şekilde gerçekleşmiştir: XGBoost (0.8539) > Random Forest (0.8374) > Lojistik Regresyon (0.8076) > Destek Vektör Makinesi (0.7945). XGBoost ile en düşük doğruluğa sahip Destek Vektör Makinesi arasındaki fark yaklaşık 6 yüzdelik puan olarak ölçülmüştür.

F1-skoru açısından bakıldığında algoritma sıralaması değişmemekle birlikte aralarındaki farklar belirgin biçimde daralmaktadır: XGBoost (0.7176), Lojistik Regresyon (0.6793), Random Forest (0.6709) ve Destek Vektör Makinesi (0.6645). F1-skorunun kesinlik ve duyarlılığın harmonik ortalaması olduğu göz önünde bulundurulduğunda bu yakınsama, algoritmaların sınıf dengesizliğini farklı biçimlerde yönettiğine işaret etmektedir [8].


6.3. Kesinlik-Duyarlılık Dengesi

Çalışmada en ilgi çekici bulgulardan biri, algoritmaların kesinlik ve duyarlılık metrikleri arasında sergilediği belirgin dengesizliktir. Lojistik Regresyon ve Destek Vektör Makinesi yüksek duyarlılık (sırasıyla 0.8462 ve 0.8448) ancak düşük kesinlik (0.5675 ve

0.5477) değerleri üretirken; Random Forest ve XGBoost daha dengeli bir kesinlik-duyarlılık profili sergilemiştir.

Bu bulgu, Lojistik Regresyon ve Destek Vektör Makinesi'nin geliri 50.000 doların üzerinde olan bireyleri yakalamada daha başarılı olduğunu, ancak bunun bedeli olarak daha fazla yanlış pozitif ürettiğini ortaya koymaktadır. Random Forest ve XGBoost ise daha temkinli bir tahmin stratejisi benimseyerek pozitif tahminlerinde daha isabetli bir tutum sergilemiştir. Literatürde de benzer bir örüntü gözlemlenmiş; Baktır ve Atay [3] Lojistik Regresyon'un farklı veri setleri üzerinde tutarlı biçimde yüksek duyarlılık değerleri ürettiğini raporlamıştır.

6.4. ROC Eğrisi Analizi




Şekil 6.1. Modeller Arası Roc Eğrisi Karşılaştırılması

Şekil 6.1'de dört algoritmanın ROC eğrileri karşılaştırmalı olarak sunulmaktadır. Tüm modeller rastgele tahmini temsil eden çapraz çizginin (AUC = 0.500) belirgin biçimde üzerinde konumlanmaktadır. AUC değerleri incelendiğinde XGBoost'un 0.925 ile açık ara en yüksek ayırt edici güce sahip olduğu görülmektedir. Lojistik Regresyon 0.907 ile ikinci sıraya yerleşirken, Destek Vektör Makinesi 0.901 ve Random Forest 0.892 değerleriyle onu izlemektedir.

ROC eğrilerinin sol üst köşeye yakınlığı incelendiğinde, düşük yanlış pozitif oranı bölgesinde (YPO < 0.20) XGBoost'un diğer algoritmalarından belirgin biçimde ayrıştığı dikkat çekmektedir. Bu bölge, yüksek kesinlik gerektiren gerçek dünya uygulamaları

açısından özellikle kritik öneme sahiptir [8]. Bentejac ve diğerlerinin karşılaştırmalı analizinde de XGBoost'un özellikle ayarlanmış parametre konfigürasyonlarında rakip yöntemlere kıyasla üstün ROC performansı sergilediği bildirilmiştir [12].

6.5. XGBoost Karmaşıklık Matrisi Analizi




Şekil 6.2. XGBoost Karmaşıklık Matrisi

Şekil 6.2'de en başarılı model olan XGBoost'un normalize karmaşıklık matrisi sunulmaktadır. Matris incelendiğinde modelin $\leq 50K$ sınıfındaki örneklerin %88'ini doğru sınıflandırdığı, %12'sini ise yanlışlıkla $> 50K$ olarak tahmin ettiği görülmektedir. $> 50K$ sınıfında ise örneklerin %80'i doğru tespit edilmiş, %20'si $\leq 50K$ olarak yanlış sınıflandırılmıştır.

Bu sonuçlar iki açıdan değerlendirilmelidir. Her şeyden önce azınlık sınıfı olan $> 50K$ için %80 doğru tespit oranı, SMOTE uygulamasının sınıf dengesizliği sorununu etkin biçimde giderdiğini göstermektedir. Öte yandan $\leq 50K$ sınıfındaki %12'lik yanlış pozitif oranı, gelir tahmini gibi uygulamalarda kabul edilebilir bir hata marjı olarak değerlendirilebilir.

6.6 XGBoost Öznitelik Önemi Analizi



Şekil 6.3. XGBoost Öznitelik Önem Grafiği

XGBoost algoritması, gradyan artırma sürecinde her özneliğin model kararlarına olan katkısını sayısal olarak ölçme imkânı sunmaktadır. Bu özellik, modelin yalnızca tahmin gücü açısından değil yorumlanabilirlik açısından da değerlendirilmesine olanak tanımaktadır [7]. Şekil 6.3'te XGBoost modeline göre hesaplanan en önemli 15 öznelik önem skoru sırasıyla sunulmaktadır.

Şekil 6.3. incelendiğinde capital-gain özneliğinin diğer tüm değişkenlerden belirgin biçimde ayrılarak en yüksek önem skoruna sahip olduğu görülmektedir. Bu bulgu, bireyin sermaye kazancının gelir düzeyi tahmini açısından en güçlü belirleyici faktör olduğuna işaret etmektedir. Söz konusu sonuç, sosyoekonomik literatürle de örtüşmektedir: yüksek sermaye kazancı genellikle yatırım gelirleri ve varlık birikiminin bir göstergesi olup yüksek gelir grubuyla güçlü bir ilişki içindedir.


İkinci sırada yer alan age özneliği, bireyin kariyer olgunluğunu ve birikim süresini yansıtmaları bakımından gelir tahmini için anlamlı bir değişken konumundadır. Üçüncü ve dördüncü sıralarda ise education-num ve hours-per-week öznelikleri yer almaktadır. Eğitim süresinin uzunluğu ile haftalık çalışma saatinin yüksekliğinin gelir düzeyini olumlu yönde etkilediği bu bulgularla bir kez daha doğrulanmaktadır.

One-Hot Encoding uygulaması sonucunda kategorik değişkenlerden türetilen alt kategoriler de önem sıralamasında yer almaktadır. Bu kategoriler arasında özellikle medeni durum ve meslek grubuyla ilişkili değişkenlerin öne çıktığı gözlemlenmektedir. capital-loss özneliği ise sermaye kaybının da gelir tahminine katkı sağladığını, ancak

sermaye kazancına kıyasla daha sınırlı bir belirleyiciliğe sahip olduğunu ortaya koymaktadır.

Bu analiz; modelin hangi bilgilere öncelik verdiğini şeffaf biçimde ortaya koyması, veri setindeki en açıklayıcı değişkenlerin belirlenmesine katkı sağlaması ve gelecekte yapılacak öznitelik mühendisliği çalışmaları için yol gösterici nitelik taşıması bakımından önem taşımaktadır [12]. Nitekim Bentejac ve diğerleri de XGBoost'un yorumlanabilirlik araçlarıyla birlikte kullanımının model şeffaflığını artırdığını vurgulamıştır [12].

6.7. Sayısal Öznitelikler Arası Korelasyon Analizi



Şekil 6.4. Sayısal Öznitelikler Arası Korelasyon Analizi

Şekil 6.4'te sayısal öznitelikler arasındaki Pearson korelasyon katsayıları ısı haritası biçiminde sunulmaktadır. Pearson korelasyon katsayısı iki değişken X ve Y arasında şu şekilde hesaplanmaktadır [2]:

$$r_{XY} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \sum_{i=1}^n (Y_i - \bar{Y})^2}} \quad (6.1)$$

Analiz sonuçlarına göre beş sayısal öznitelik arasında güçlü bir doğrusal ilişki bulunmamaktadır. En yüksek korelasyon education-num ile hours-per-week arasında gözlemlenmiş olup bu değer yalnızca 0.15 düzeyinde kalmaktadır. capital-gain ile capital-loss arasında ise hafif negatif bir ilişki (-0.03) saptanmıştır. Bu bulgu, öznitelikler

arasındaki düşük korelasyonun çoklu doğrusallık sorununa işaret etmediğini ve her öz niteliğin modele bağımsız bilgi katkısı sağladığını göstermektedir [2].

6.8. Algoritmaların Genel Değerlendirmesi

Elde edilen bulgular bütünsel olarak değerlendirildiğinde şu çıkarımlar öne çıkmaktadır. XGBoost, dört metrikte birinci sırada yer alarak bu çalışmanın en başarılı algoritması konumuna gelmiştir. Gradyan arttırma mekanizması ve düzenleme parametrelerinin sağladığı esneklik, algoritmanın hem doğruluk hem de ayırt edici güç bakımından üstün performans sergilemesine zemin hazırlamıştır [7]. Lojistik Regresyon ise duyarlılık metriğindeki üstünlüğü ve 0.905 AUC değeriyle dikkate değer bir performans ortaya koymuş; hesaplama verimliliği ve yorumlanabilirliği göz önünde bulundurulduğunda hız ve şeffaflığın ön planda olduğu uygulamalar için geçerli bir tercih olmaya devam etmektedir [3]. Random Forest, dengeli kesinlik-duyarlılık profiliyle güvenilir sonuçlar üretmekle birlikte ROC-AUC bakımından diğer üç algoritmanın gerisinde kalmıştır [6]. Destek Vektör Makinesi ise doğruluk ve kesinlik metriklerinde en düşük değerleri üretmiş; büyük veri setlerinde eğitim süresinin belirgin biçimde uzaması da pratik uygulanabilirliğini sınırlandıran bir etken olarak öne çıkmıştır [5].

7. SONUÇ VE ÖNERİLER

7.1 Genel Sonuçlar

Bu çalışmada, UCI Adult-Census Income veri seti üzerinde Lojistik Regresyon, Destek Vektör Makinesi, Random Forest ve XGBoost algoritmalarının ikili sınıflandırma performansı karşılaştırmalı biçimde incelenmiştir. Veri ön işleme, sınıf dengeleme ve model değerlendirme adımları pipeline mimarisi altında bütünleştirilmiş; 10 katlı tabakalı çapraz doğrulama yöntemiyle modellerin genelleme başarısı güvenilir biçimde ölçülmüştür.

Elde edilen bulgular beş temel başlık altında özetlenebilir:

XGBoost en başarılı algoritma olmuştur. Doğruluk (0.8539), Kesinlik (0.6715), F1-skoru (0.7176) ve ROC-AUC (0.9227) metriklerinde en yüksek değerlere ulaşan XGBoost, gradyan artırma mekanizması ve yerleşik düzenleme parametreleri sayesinde hem aşırı uyum sorununu kontrol altında tutmuş hem de güçlü bir ayırt edici güç sergilemiştir. Bu bulgu, Bentejac ve diğerlerinin geniş kapsamlı karşılaştırmalı analizindeki bulgularla örtüşmektedir [12].

Lojistik Regresyon duyarlılık metriğinde öne çıkmıştır. En yüksek duyarlılık değerine (0.8462) ve rekabetçi bir ROC-AUC skoruna (0.9050) ulaşan Lojistik Regresyon, yanlış negatiflerin maliyetinin yüksek olduğu uygulamalar için geçerli bir tercih olmaya devam etmektedir. Baktır ve Atay'ın spam sınıflandırma çalışmasında da Lojistik Regresyon'un farklı veri setleri geneline tutarlı ve güvenilir sonuçlar ürettiği gözlemlenmiştir [3].

SMOTE azınlık sınıfı tespitini etkin biçimde iyileştirmiştir. XGBoost'un karmaşıklık matrisinde >50K azınlık sınıfı için %80 doğru tespit oranı elde edilmesi, pipeline içine entegre edilen Chawla ve diğerleri [10] tarafından geliştirilen SMOTE uygulamasının sınıf dengesizliği sorununu başarıyla giderdiğini ortaya koymaktadır. Güvenç ve diğerlerinin çalışmasında da benzer biçimde SMOTE'un azınlık sınıfı başarısını belirgin biçimde artırdığı raporlanmıştır [4].

Sayısal öznitelikler arasında anlamlı bir doğrusal ilişki saptanmamıştır. Korelasyon analizi, veri setindeki sayısal değişkenlerin birbirinden büyük ölçüde bağımsız olduğunu ve her birinin modele özgün bilgi katkısı sunduğunu göstermiştir. Bu bulgu, öznitelik azaltma işlemi uygulanmaksızın doğrudan modelleme yapılmasının yerinde bir karar olduğunu desteklemektedir [2].

Destek Vektör Makinesi büyük veri setlerinde pratik sınırlar sergilemiştir. Doğruluk ve kesinlik metriklerindeki görece düşük performansının yanı sıra eğitim süresinin diğer algoritmalara kıyasla belirgin biçimde uzun olması, Cortes ve Vapnik [5] tarafından geliştirilen DVM'nin bu ölçekteki veri setleri için etkinliğini sınırlandırmaktadır. Abdullah ve Abdulazeez'in incelemesinde de DVM'nin büyük ölçekli verilerde zaman ve bellek karmaşıklığının doğrusal olarak arttığı vurgulanmıştır [11].

7.2 Çalışmanın Katkıları

Bu çalışma birkaç açıdan literatüre katkı sunmaktadır. Her şeyden önce, dört farklı algoritmayı aynı veri seti ve aynı deneysel kurulum üzerinde tek bir başarımlı metriğine bağlı kalmaksızın beş farklı ölçütle karşılaştıran bütünlük bir değerlendirme çerçevesi ortaya konulmuştur. Bunun yanı sıra SMOTE tabanlı sınıf dengelemenin pipeline yapısı içine alınması, veri sızıntısı riskini ortadan kaldırarak metodolojik güvenilirliği artırmıştır [10]. Son olarak gerçek dünya niteliği taşıyan, eksik değerler ve sınıf dengesizliği içeren bir veri seti üzerinde yürütülen bu çalışma, benzer özelliklerdeki sınıflandırma problemleri için pratik bir referans niteliği kazanmaktadır [9].

7.3 Sınırlılıklar

Çalışmanın bazı sınırlılıkları bulunmaktadır. Algoritma parametreleri varsayılan değerler üzerinden kullanılmış olup hiperparametre optimizasyonu uygulanmamıştır. Bunun yanı sıra analiz tek bir veri setiyle sınırlı kalmıştır; bulguların farklı alan ve ölçeklerdeki veri setlerine genellenebilirliği ayrıca incelenmelidir. Ayrıca eğitim süreleri sistematik biçimde kayıt altına alınmamış olup algoritmaların hesaplama maliyeti karşılaştırması bu çalışmanın kapsamı dışında tutulmuştur.

7.4 Gelecek Çalışma Önerileri

Bu çalışmadan hareketle aşağıdaki araştırma yönleri önerilebilir:

Hiperparametre optimizasyonu: Grid search veya Bayesian optimizasyon yöntemleriyle algoritmaların en uygun parametre konfigürasyonlarının belirlenmesi, özellikle XGBoost [7] ve Random Forest [6] için ek performans kazanımı sağlayabilir.

Farklı veri setlerine uygulanması: Sağlık, finans ve siber güvenlik gibi farklı alanlardaki ikili sınıflandırma veri setleri üzerinde aynı metodolojinin tekrarlanması, bulguların genellenebilirliğini test etmeye olanak tanıyacaktır [2].

Öznitelik mühendisliği: Mevcut özniteliklerin dönüştürülmesi veya yeni özniteliklerin türetilmesi yoluyla model performansının iyileştirilmesi araştırılabilir.

Derin öğrenme yöntemleriyle karşılaştırma: Geleneksel makine öğrenmesi algoritmalarının yapay sinir ağları ve derin öğrenme tabanlı sınıflandırıcılarla karşılaştırılması, literatüre değerli katkılar sunabilir [1].

KAYNAKÇA

- [1] Pandey, D., Niwaria, K. ve Chourasia, B. (2019). Machine Learning Algorithms: A Review. *International Research Journal of Engineering and Technology (IRJET)*, 6(2), 916-922.
- [2] Kalaycı, T. E. (2018). Kimlik hırsız web sitelerinin sınıflandırılması için makine öğrenmesi yöntemlerinin karşılaştırılması. *Pamukkale Üniversitesi Mühendislik Bilimleri Dergisi*, 24(5), 870-878.
- [3] Baktır, N. ve Atay, Y. (2022). Makine Öğrenmesi Yaklaşımlarının Spam-Mail Sınıflandırma Probleminde Karşılaştırmalı Analizi. *Bilişim Teknolojileri Dergisi*, 15(3), 349-364.
- [4] Güvenç, E., Sakal, M., Çetin, G. ve Özkaraca, O. (2022). Öğrencilerin Dersteki Niteliklerinin Makine Öğrenmesi Teknikleri Kullanılarak Sınıflandırılması. *Düzce Üniversitesi Bilim ve Teknoloji Dergisi*, 10, 1359-1371.
- [5] Cortes, C. ve Vapnik, V. (1995). Support-Vector Networks. *Machine Learning*, 20(3), 273-297. DOI: 10.1007/BF00994018
- [6] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32. DOI: 10.1023/A:1010933404324
- [7] Chen, T. ve Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, San Francisco, 13-17 Ağustos 2016, s. 785-794. DOI: 10.1145/2939672.2939785
- [8] Berrar, D. (2018). Performance Measures for Binary Classification. *Encyclopedia of Bioinformatics and Computational Biology*. Elsevier.
- [9] Becker, B. ve Kohavi, R. (1996). Adult [Dataset]. *UCI Machine Learning Repository*. <https://doi.org/10.24432/C5XW20>
- [10] Chawla, N. V., Bowyer, K. W., Hall, L. O. ve Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321-357. DOI: 10.1613/jair.953
- [11] Abdullah, D. M. ve Abdulazeez, A. M. (2021). Machine Learning Applications based on SVM Classification: A Review. *Qubahan Academic Journal*, 1(2), 81-90.
- [12] Bentejac, C., Csörgő, A. ve Martínez-Muñoz, G. (2019). A Comparative Analysis of XGBoost. *arXiv:1911.01914*.
- [13] Liu, Y., Wang, Y. ve Zhang, J. (2012). New Machine Learning Algorithm: Random Forest. *LNCS*, 7473, 246-252.

ÖZGEÇMİŞ

Ad Soyad	Tahire Gülnur Turanlı	
Doğum Tarihi	13.07.1999	
Doğum yeri	Iğdır	
İlkokul	Fikret Yüzatlı İlkokulu	
Ortaokul	Fikret Yüzatlı Ortaokulu	
Lise	Avcılar Anadolu Lisesi	
Staj Yaptığı Yerler	Sca Social	-(4 hafta)
	Mitos Medikal Teknoloji A.Ş.	-(4 hafta)